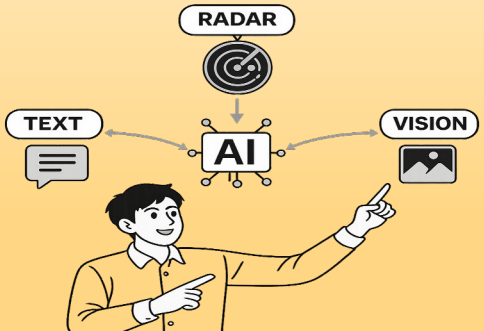
멀티모달 융합 AI 기반으로 “보이지 않는 정보” 까지 이해하는 기술을 만듭니다

신정완 | Postdoctoral Researcher



CONTACT
Phone : 010-8977-8501
E-mail : jwshin@dgist.ac.kr
CV : https://jeongwan-shin.github.io/
Git : https://github.com/Jeongwan-Shin

신정완 | Postdoctoral Researcher



학력 및 현황

◆ 학력 및 경력

- 경북대학교 석사 ('18)
- 경북대학교 박사 ('25)
- KAIST InnoCoreLLM 박사후연구원-Working at DGIST ('25~'26)

학술 역량

AI 연구과제	8 건
AI 관련 논문	10 편

주요 연구 분야

- **Video-LM**
- **Physical-AI**
- **Autonomous Driving**
- **Radar-AI**

주요 연구 업적

- NLP, CV, Physical-AI, Radar-AI 등 **다양항 분야**에서 연구활동 수행
- AI 관련 SCI 학술지 및 최우수 학술대회 10편 게재 (주저자 7편)
- Radar AI 관련 **국내 유일하게** LLM과 연동하여 CVPR, Neurips에서 발표
- CVPR, WACV, ACL, Neurips, ICLR 등 다양한 AI 분야 논문 및 **Reviewer 활동**
- Text-Diffusion Model, Rainforcement Learning 등 **Invited Talk** 진행

AI 연구 과제

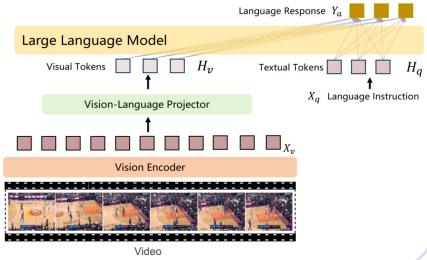
- **LLM InnoCore 사업단:** Radar+LLM 및 VLA 학습데이터 생성 및 학습 파이프라인 구축
- **디지털 콜럼버스 프로젝트:** 공장 안전 관련 멀티 센서 융합 모델 개발
- **LG Electronics 에어컨 공장 자동 검증:** Test Code generation Tool Agent 개발
- **스마트 보고서로 요약:** LLM이 요약한 보고서에서 hallucination 검증 및 수정
- **비디오 튜링 테스트:** Video QA 연구 및 개발
- **WiseKB:** Document Summarizaition 모델 연구 및 개발

주요 연구 분야 및 경험

Video-LM

LM/VLM 기반 문서/영상 이해, 요약, 환각 검출 수정, RAG, Video QA 및 추론 시점 확장 연구

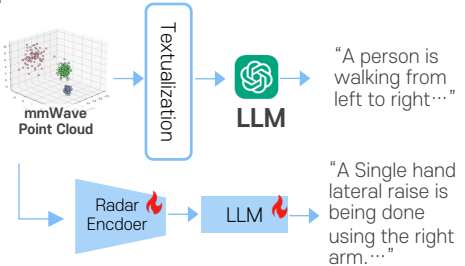
- Document Summarization
- Hallucination detection & correction
- Retrieval-Augmented Generation (RAG)
- Video-LM: QA, inference-time scaling



Radar-AI

Radar 신호를 LLM이 이해하기 위한 표현 학습 및 멀티모달 모델링 연구

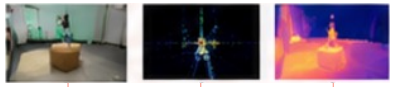
- LLM의 human pose mmWave 데이터 이해 능력 평가 및 벤치마크 구축
- Radar 신호의 Textualization을 통한 Instruction tuning 방법 제안
- mmWave radar 포인트 클라우드를 직접 LLM에 입력하기 위한 encoder 설계 및 학습 방법 제안



Physical-AI

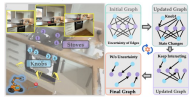
Vision 중심의 VLM/VLA를 넘어, 다양한 센서 (Radar, IR 등)가 입력 가능한 FM모델 연구

- 멀티센서(Vision, Radar, IR 등)가 입력 가능한 VLM/VLA 개발 및 학습
- Robot manipulation, navigation 등 다양한 Physical AI 로 확장
- 실세계 데이터 및 시뮬레이터 기반 학습
- (Radar-equipped simulator)
- Scene understanding 에서 Action Selection을 연결하는 멀티모달 VLM 개발



Multi-sensor VLM/VLA

Scene Understanding
(Scene graph, reasoning)



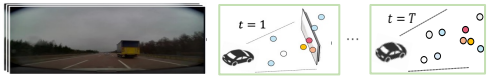
Action Execution
(Manipulation / navigation)



Autonomous Driving

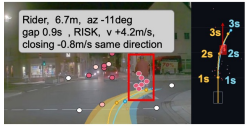
Vision 기반 VLM을 넘어, Radar가 입력 가능한 자율주행 파운데이션 모델 연구 및 개발

- Camera + Radar + Language 기반 주행 상황 이해 및 경로생성
- Radar-aware VLM/VLA 모델
- 멀티센서 인지, 예측, 계획 및 end to end 학습



Radar-aware VLM

Driving Rationale (CoT)
"With the ego moving at 5.1m/s and slightly decelerating, while a rider 6.7m ahead at -11deg azimuth with a -0.8m/s …. "



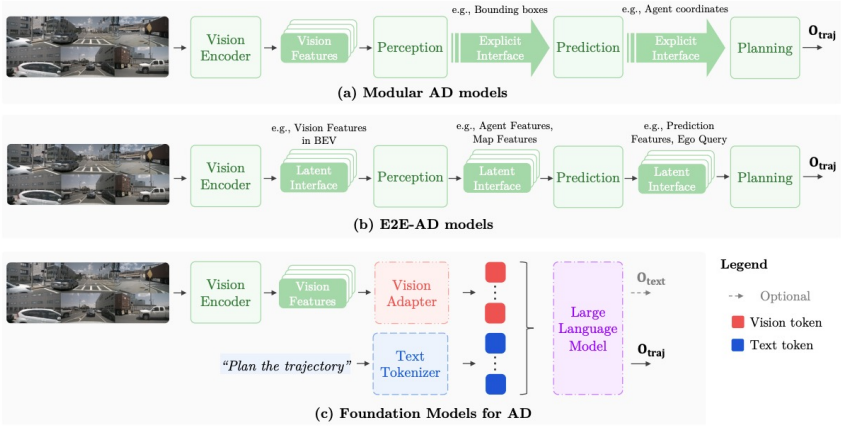
RAPHY-AD (ICLR 2027 Submission)

Radar-Aware Foundation Model with Explicit Physical Chain-of-Thought for Autonomous Driving

Vision을 넘어 mmWave Radar의 거리·방위각·도플러 속도를 명시적 물리 추론으로 변환해 VLM이 Autonomous Vehicle에 대한 궤적 예측을 강화합니다.

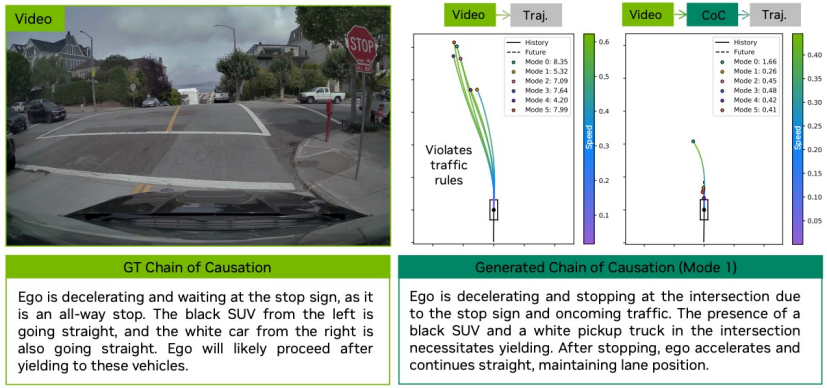
VLMs for Autonomous Driving: From Perception to Reasoning

- 자율주행 아키텍처의 발전 과정



- VLM Foundation Model: 인지·예측·계획을 하나의 모델로 통합하고, 범용 사전학습 지식을 활용
- World Knowledge & Reasoning: 대규모 웹 데이터에서 학습한 지식과 추론 능력을 활용해 복잡한 주행 상황을 이해

- 왜 언어 기반 추론이 필요한가?

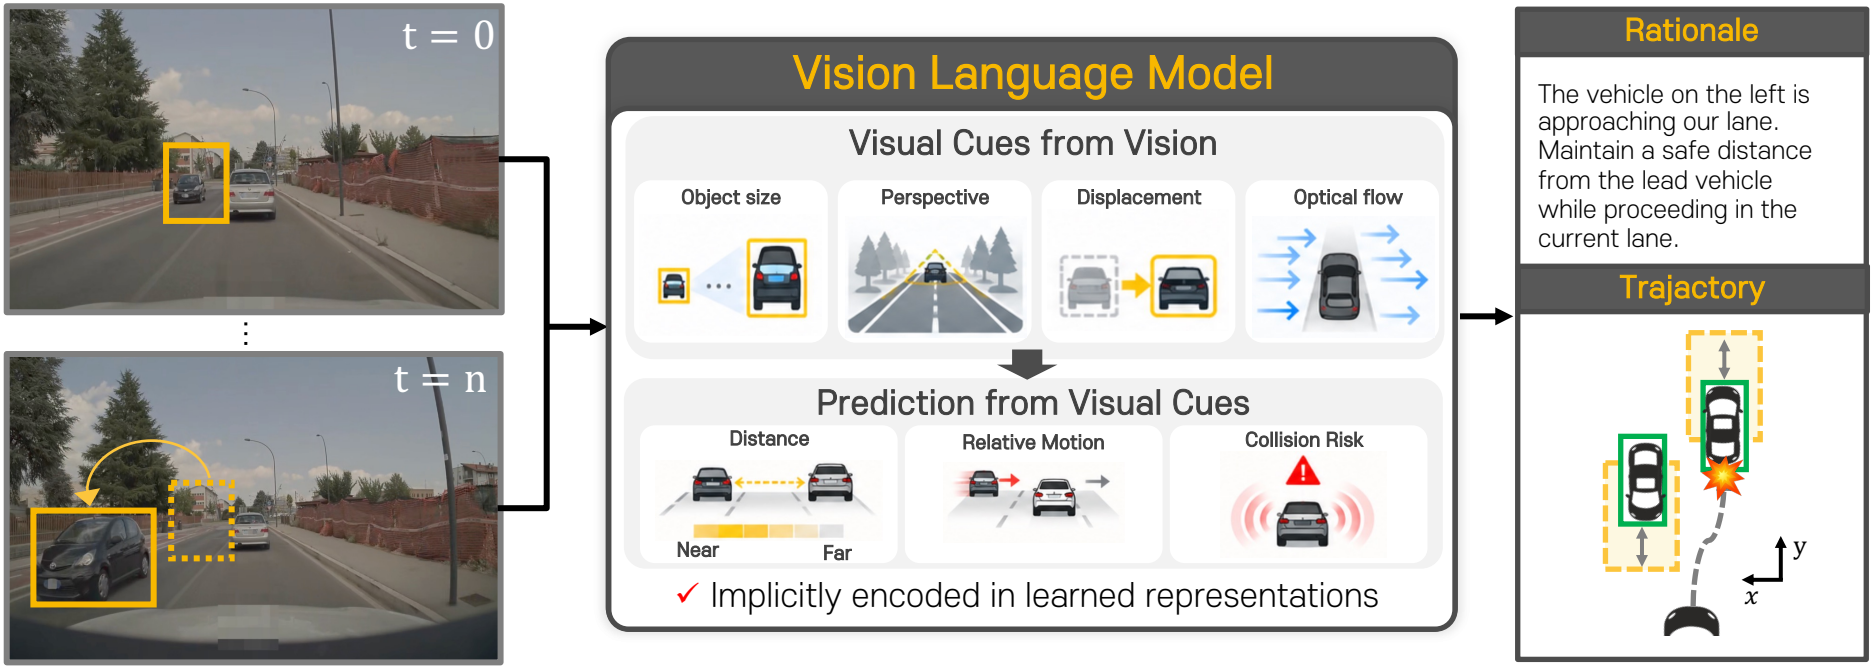


- Explainable Driving Reasoning: 궤적 예측을 넘어 상황 → 행동 이유 → 대응 방법을 rationale로 설명
- 언어 기반 rationale은 주행 판단의 근거를 명시적으로 드러내어 해석 가능성을 높임

✓ 하지만 아직까지 Vision 기반의 rationale은 거리·상대속도와 같은 물리량을 명시적으로 grounding하지 못함

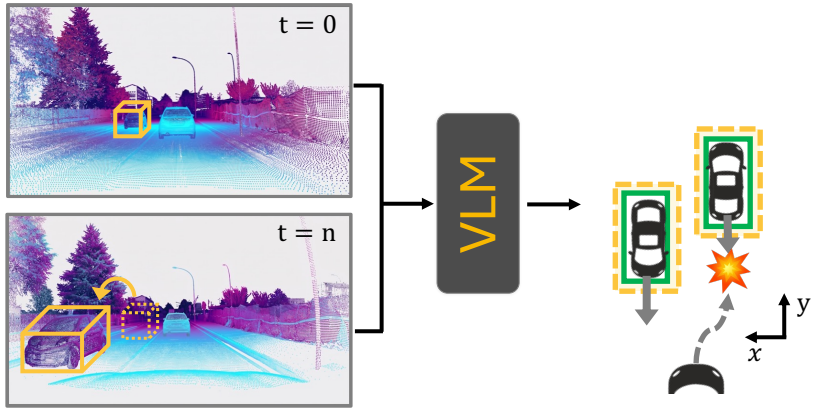
[1] Foundation Models for Trajectory Planning in Autonomous Driving: A Review of Progress and Open Challenges (TMLR 2026)
[2] UniAD: "Planning-oriented Autonomous Driving (CVPR 2023)
[3] Alpamayo 1: Bridging Reasoning and Action Prediction for Generalizable Autonomous Driving in the Long Tail (arXiv 2025)

VLMs Infer Physical Information Implicitly from Vision



- **Distance:** 객체 크기, 원근감, 도로 구조 등의 visual cues를 기반으로 암묵적으로 추정
- **Relative Motion:** 프레임 간 위치·크기 변화 및 optical flow를 기반으로 암묵적으로 추정

Beyond Vision: Sensors for Explicit Physical Evidence

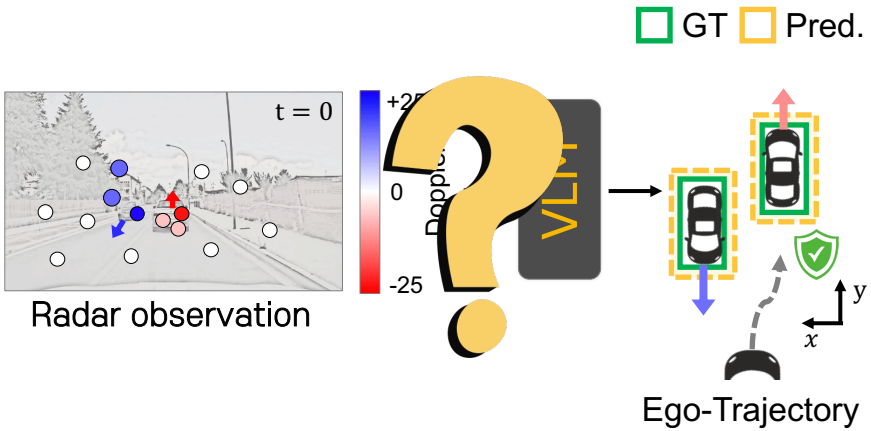


LiDAR observation

Ego-Trajectory

Distance	Measured
Motion	Estimated
Semantics	Limited

✓ Explicit geometry, implicit/estimated motion



Radar observation

Ego-Trajectory

Distance	Measured
Motion	Measured
Semantics	Limited

✓ Explicit geometry and relative motion

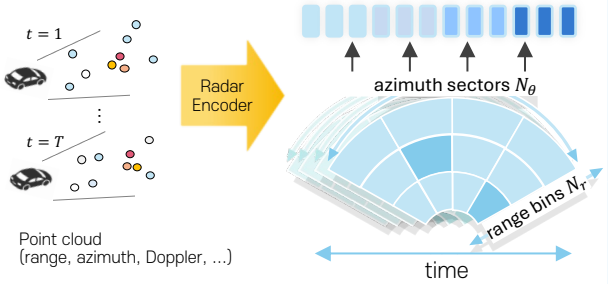
- **레이더(Radar)**는 기존 VLM이 시각적 관찰을 통해 암묵적으로 추론해야 하는 물리량을 직접 제공

그렇다면 레이더가 측정한 물리량을 활용해, **VLM의 추론을 어떻게** 현실 세계의 물리적 상태에 grounding 할 수 있을까?

What Is Needed to Bring Radar into VLMs?

Radar Point Cloud를 VLM이 이해할 수 있는 형태로 어떻게 표현할 것인가?

레이더의 거리·방위각·Doppler·시간 정보를 보존하면서 VLM 입력 토큰으로 변환



Radar Encoder

- ✓ Radar의 물리적 구조 보존: 거리(range), 방위각(azimuth), Doppler, temporal 정보 유지
- ✓ Radar observation을 VLM-compatible token으로 변환

물리량을 어떻게 명시적으로 표현할 것인가?

일반적인 tokenizer는 수치값을 여러 토큰으로 분할하고, 물리 단위와의 결합 관계를 충분히 반영하지 못함

Standard Tokenizer (e.g., LLaMA, Qwen)

`-` `1` `.` `6` `d` `e` `g` — 5 tokens (no unit binding)

Physical-Aware Tokenizer (ours)

`-1.6deg` — 1 tokens (atomic + unit)

Physical-Aware Tokenizer

- ✓ Atomic numeric tokens: 숫자값 자체를 하나의 토큰으로 표현
- ✓ Unit-integrated physical tokens: 숫자와 단위를 결합한 물리량을 하나의 토큰으로 표현

물리 기반 reasoning을 어떻게 학습할 것인가?

Radar와 Vision으로부터 물리적 rationale을 생성하고, SFT와 GRPO with RLVR를 통해 수치적으로 정확하고 일관된 추론 학습

자율주행 테스크 데이터 생성



Training: SFT → GRPO with RLVR

SFT (Supervised Fine-Tuning)
- Radar-aware perception 및 physical reasoning 적응
- Tokenizer 및 radar 학습

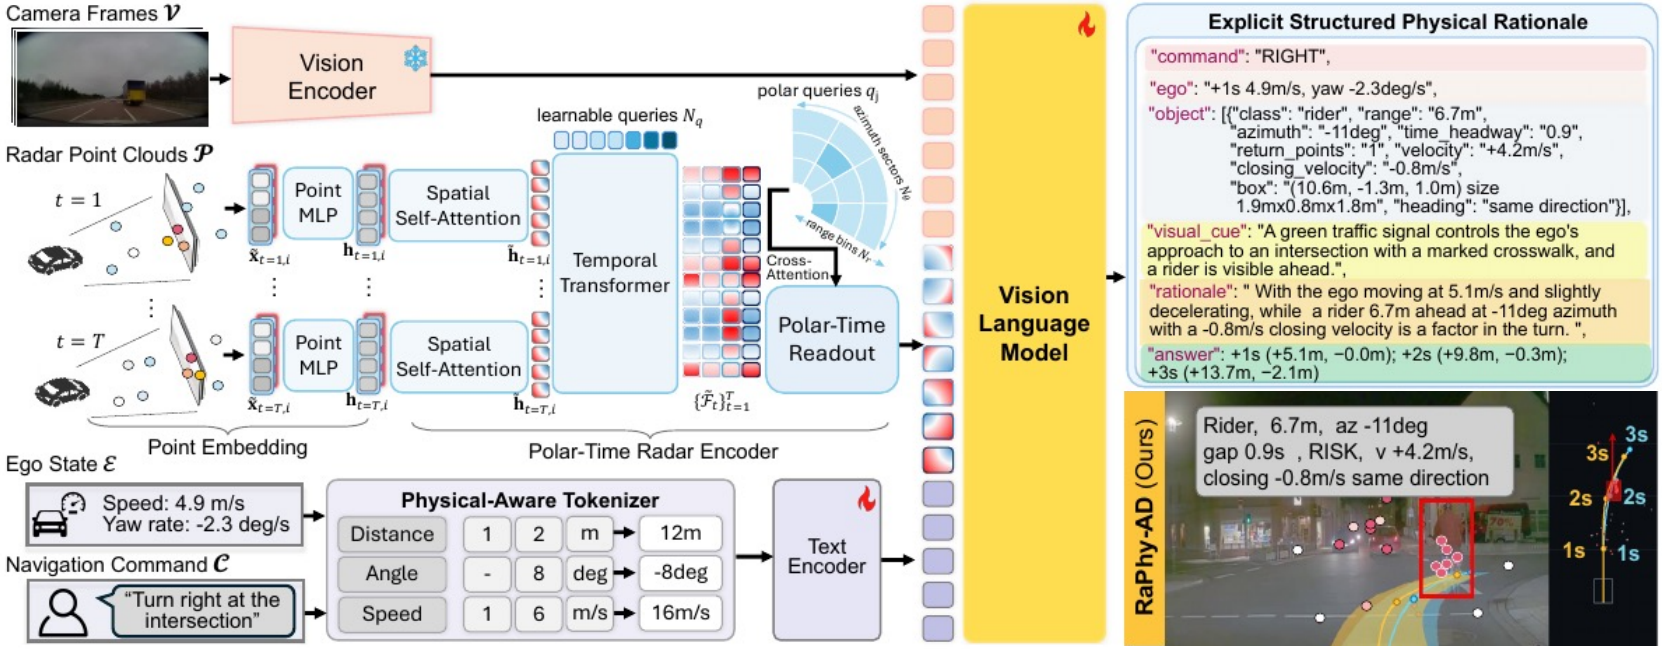
GRPO with RLVR (Reward-based RL)
- SFT 이후 물리량 및 궤적 예측 정확도 정교화
- 생성된 응답 그룹의 검증 가능한 보상으로 학습
- 별도 value network 없이 physical reasoning 개선

RaPhy-AD

Radar-Aware Vision Language Foundation Model

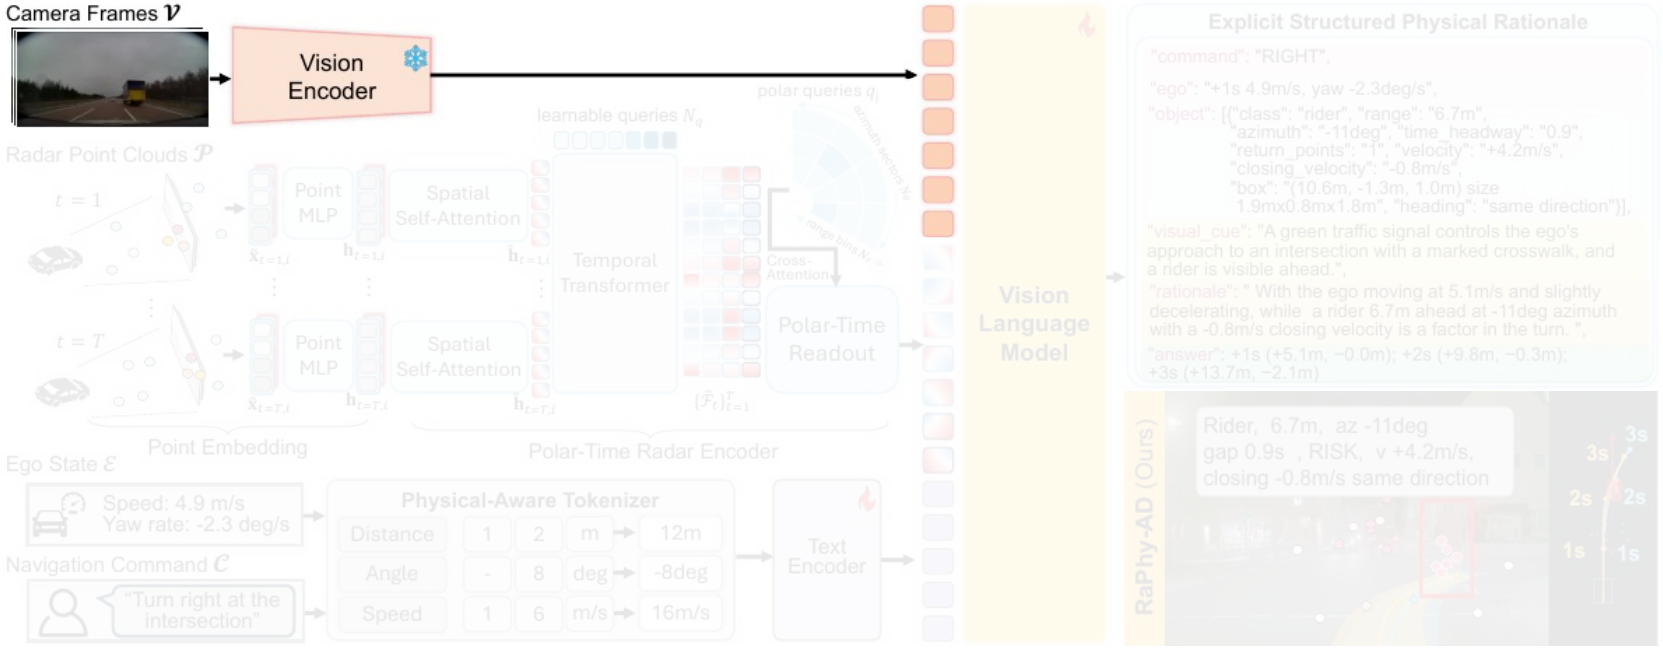
→ Explicit Physical Reasoning Trajectory Planning

Method Overview: RaPhy-AD Architecture



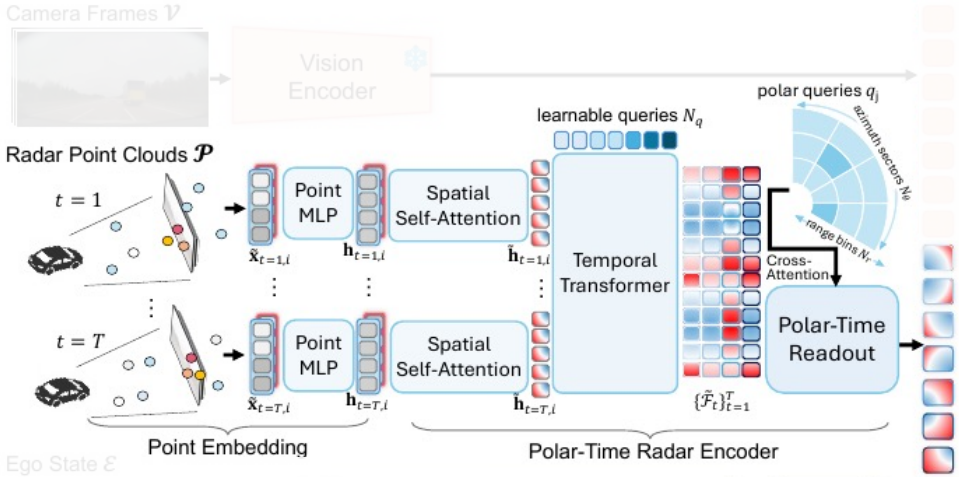
- RaPhy-AD는 카메라, 레이더, 자차 상태, 그리고 주행 명령을 하나의 vision-language framework 안에서 통합적으로 인코딩
- 또한 미래 궤적을 예측하기 전에, 물리 정보를 명시적으로 포함한 structured rationale을 먼저 생성

RaPhy-AD: Vision Encoder



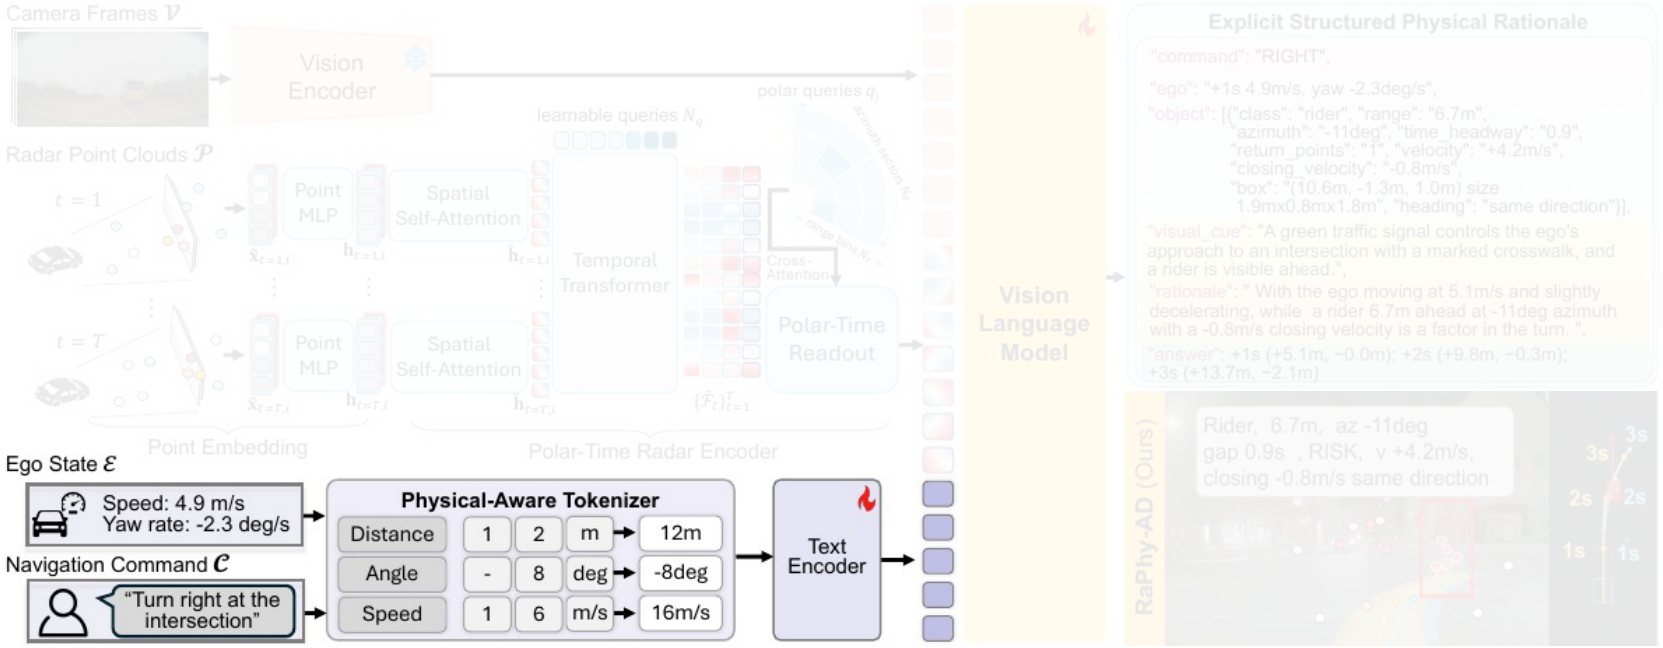
- Pretrained Vision Encoder를 통해 camera frame을 visual token으로 변환
- 객체·도로·신호 등 풍부한 semantic information을 VLM에 제공

RaPhy-AD: Radar Encoder



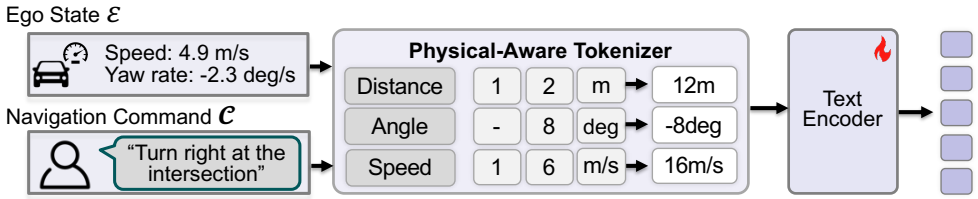
- 각 Radar point의 거리·방위각·Doppler와 같은 물리 정보를 point embedding으로 표현하고, spatial self-attention으로 프레임 내 객체 관계를 학습
- Temporal Transformer와 Polar-Time Readout을 통해 시간적 변화와 polar 구조를 통합하여 VLM 입력을 위한 radar token을 생성

RaPhy-AD: Physical Aware Tokenizer

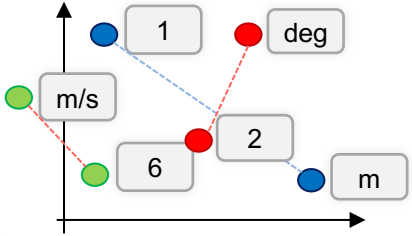


- 거리·각도·속도와 같은 물리량을 수치와 단위가 결합된 하나의 token으로 표현하여 physical semantics를 보존
- Ego state와 navigation command를 VLM이 안정적으로 해석할 수 있는 text representation으로 변환

RaPhy-AD: Physical Aware Tokenizer

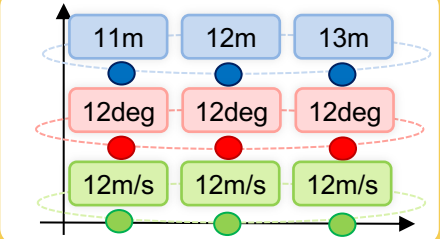


기존 토큰 공간: Token Space (Standard, Qwen tokenizer)



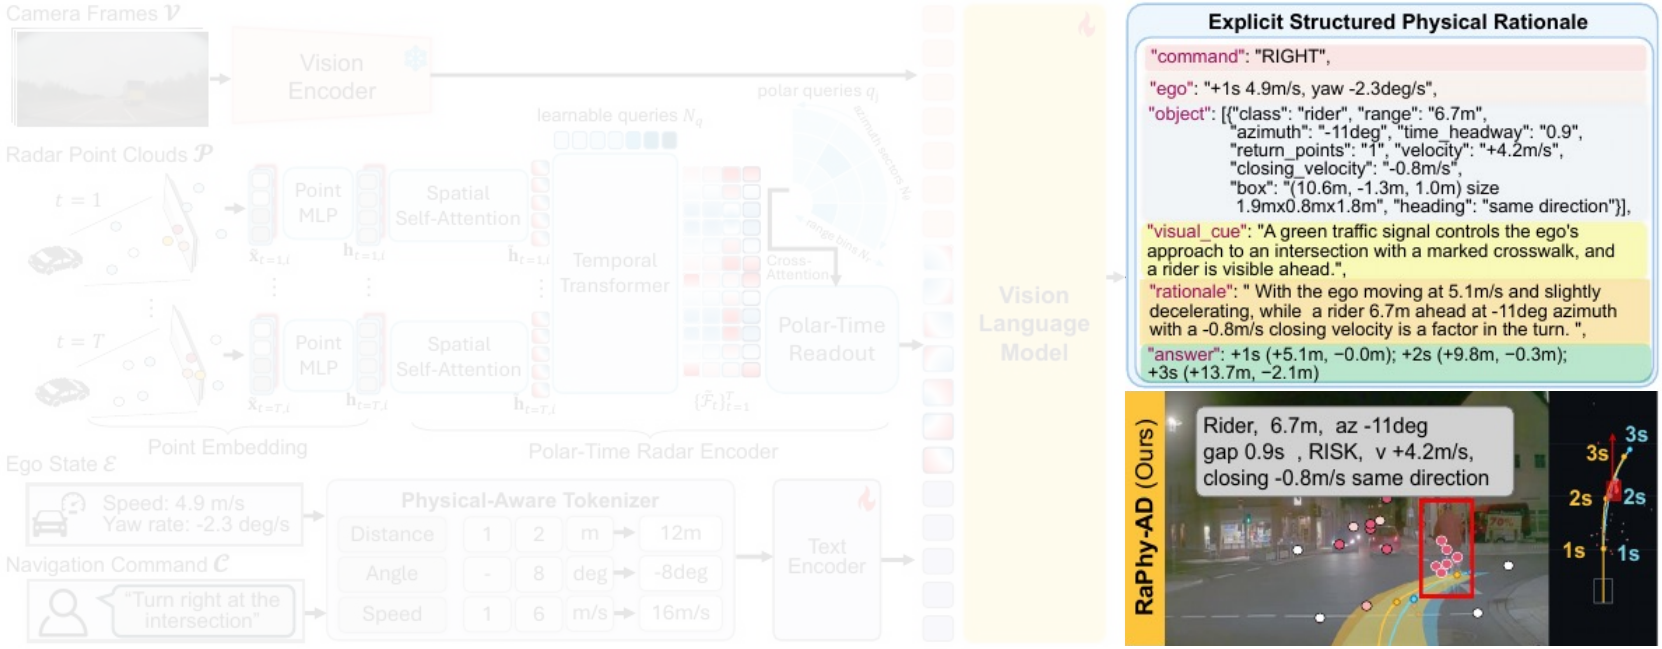
- **수치와 단위의 분리:**
  - 거리(12, m), 각도(-8, deg), 속도(16, m/s)처럼 숫자와 단위가 각각 독립된 **개별 토큰**으로 처리
- **상관관계 부재 및 무작위 분포:**
  - 임베딩 공간(Token Space) 상에서 숫자 토큰과 단위 토큰 **사이에 물리적·의미적 연결 고리가 없음**
  - 각 토큰이 공간 내에 **규칙성 없이** 무작위로 흩어져 있음 (Scatter without relation)
- **한계점:**
  - 모델 입장에서는 12라는 숫자가 **거리**를 뜻하는지 **속도**를 뜻하는지 파악하기 어려움
  - **수치의 크고 작음**(예: 10과 12의 연속성)이나 **물리량 간의 관계**를 공간적 위치로 학습하지 못함

Physical-Aware Tokenizer



- **수치와 단위의 단일 토큰화:**
  - 숫자와 단위를 분리하지 않고 10m와 같이 하나의 통합된(Unified) 토큰으로 묶어서 정의
- **물리량(단위)별 군집 형성:**
  - 임베딩 공간에서 거리(m), 각도(deg), 속도(m/s) 등 동일한 물리적 속성을 가진 토큰끼리 정렬
- **수치적·공간적 연속성 보존:**
  - 각 물리량 그룹 내부에서 토큰들이 수치의 크기 순서대로 나란히 배치
  - 모델이 토큰 공간 내의 위치와 거리만으로도 실제 물리량의 크기 차이와 수치 간 상관관계를 직관적이고 연속적으로(Ordered/Continuous representation) 이해

RaPhy-AD: Explicit Structured Physical Rationale



- 주행 명령, ego state, 객체별 거리·방위각·상대속도, visual cue를 구조화된 rationale로 명시적으로 생성
- 물리적 근거를 바탕으로 driving rationale을 구성한 뒤, 이를 통해 최종 trajectory를 예측

Training Stage: Training Data Generation

Raw Driving Clip pool (NVIDIA PhysicalAI-AV, 160,761 radar-equipped clips) 다양한 주행 환경에서 수집된 레이더 장착 주행 클립



Multi-view Camera (Video)



mmWave Radar (point cloud)

Speed: 4.9 m/s
Yaw rate: -2.3 deg/s

Ego State

location, time, weather, map, traffic density, …

Metadata (annotation)

1 Long-tail 시나리오 클립 선정

VLM과 사람의 라벨링, RAG를 활용하여 다양한 long-tail 주행 시나리오를 선별하고 확장

1.A Description Generation



"dense urban intersection with a cut-in vehicle approaching rapidly from the left while a pedestrian is near the crosswalk"

VLM이 video clip의 장면과 interaction을 요약

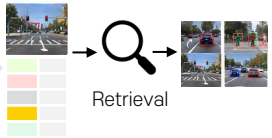
1.B Human annotation



시나리오 유형	차선변경, 컷인, …
주요 상호작용	Lead vehicle, crossing, …
도로구조	Crosswalk, stop line, …
환경조건	Night, fog, rain, …
…	…

사람이 직접 1000개 clip에 대한 카테고리 및 meta 정보라벨링

1.C Video+metadata RAG



video와 metadata 기반 RAG로 유사한 clip을 검색 및 확장



lane change | pedestrian/cyclist | intersection | cut-in | dense traffic | parking lot | night / fog / snow

2 멀티 테스크 학습 데이터 생성

선정된 long-tail 시나리오 클립을 다양한 태스크의 멀티모달 instruction-response 쌍으로 변환

2.A SFT Training Data

video clip + metadata

programmatic + LLM-assisted



2.B Explicit Structured Physical Rationale

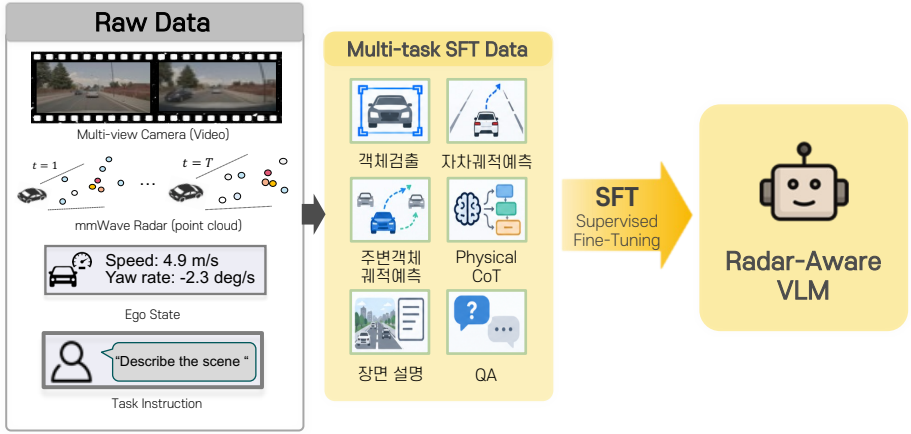
Command	Ego State	Object Physical States	Visual Cues	Driving Rationale	Trajectory
"Turn right at the intersection."	speed, yaw rate, …	position, velocity, size, heading, …	lane, traffic light, …	CoT reasoning, safety, rules	multi-step trajectory ([x,y], [x,y], …)

Our Training Corpus: 160,761 radar-equipped clips / 2,984,608 multimodal instruction-response pairs

1,210 held-out test clips reserved separately

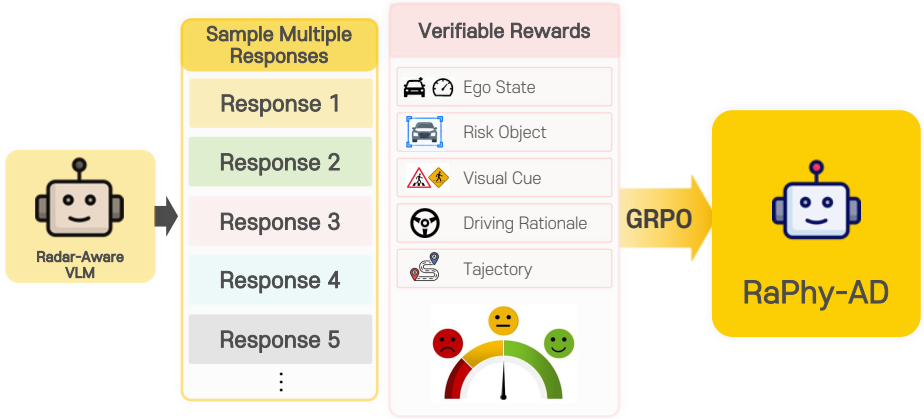
Two-Stage Training for physical Reasoning

1) Supervised Fine-Tuning (SFT)



- 다양한 자율주행 task supervision을 통해 radar-aware perception과 reasoning 형식을 학습
- Polar-Time Radar Encoder, VLM backbone을 공동 학습 적용

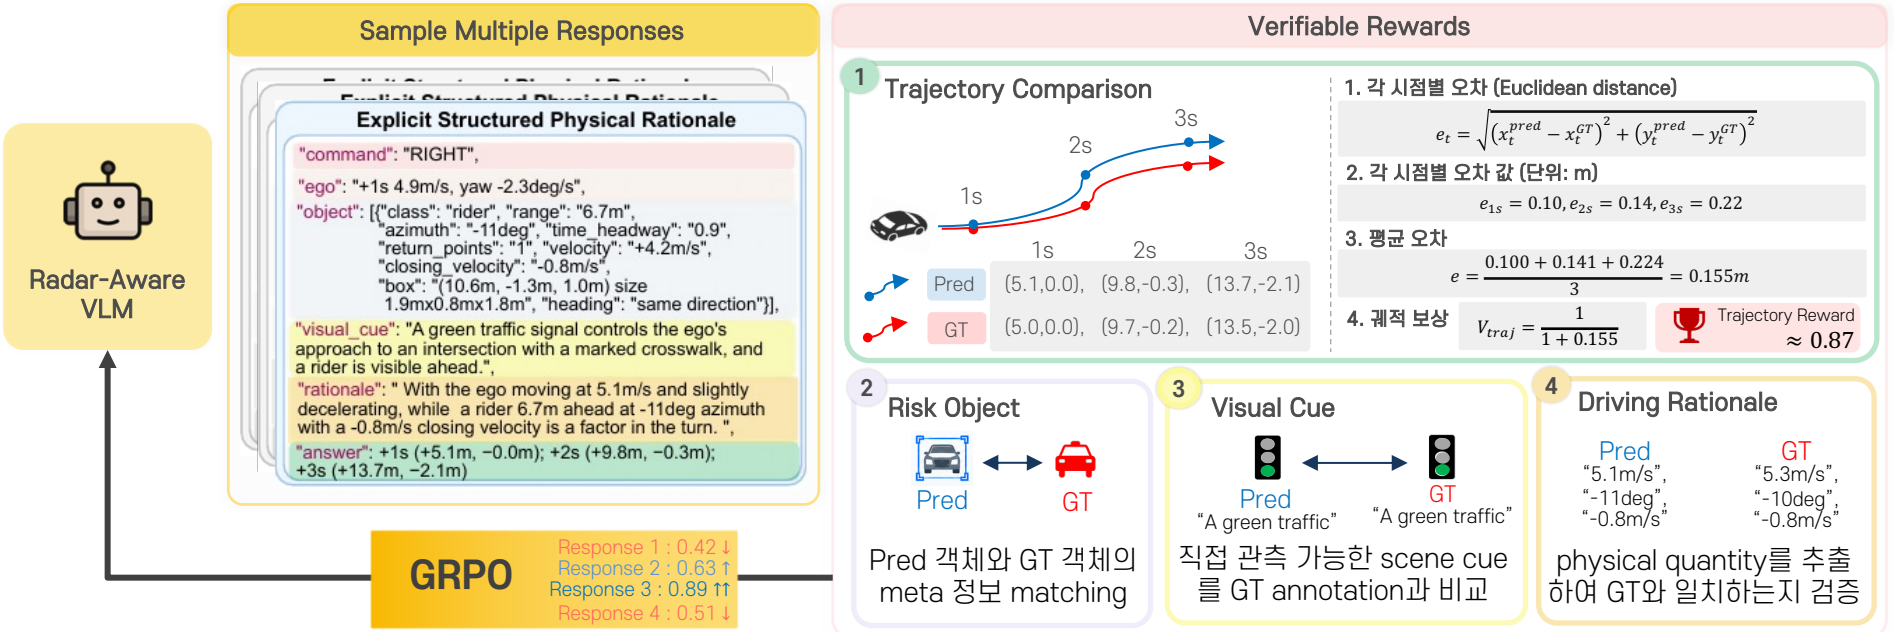
2) GRPO with RLVR



- Pysical GT와 직접 비교 가능한 reward로 물리량 및 trajectory의 수치적 정확성을 강화
- 별도 reward model 없이 response의 상대적 보상으로 policy를 개선

SFT는 추론 형식을 학습하고, GRPO+RLVR은 물리적 정확성과 일관성을 향상

Reward Details



- 각 scene에서 여러 response를 샘플링하고, trajectory, risk object, visual cue, rationale consistency를 GT와 직접 비교하여 verifiable reward를 계산
- GRPO는 group-relative advantage를 통해 high-reward response의 확률을 높이고 low-reward response는 낮추어, 물리적으로 더 정확한 reasoning과 trajectory를 강화

Experimental Setup

- **Test Set**
  - 1,210 held-out driving clips / 1,287 trajectory anchors
  - Physical information이 중요한 diverse & challenging driving scenarios 중심으로 구성
  - 기존 PhysicalAI-AV evaluation split의 644 radar-equipped clips 포함
- **Scenario Composition**
  - Ego Behavior: Lane Keeping, Lane Change, Start After Stop
  - Interaction: Pedestrian / Cyclist, Cut-in, Dense Traffic
  - Adverse Environment: Snow, Fog, Night
- **Evaluation Protocol**
  - Prediction Horizon: 1 s / 2 s / 3 s
  - Metrics: L2 Error ↓ / Collision Rate ↓
- **Experiments:**
  - Main VLM/VLA Comparison, Zero-shot on nuScenes, Scenario Evaluation, Radar Ablation, Component Ablation, Rationale Analysis

Main Results

Table 2: Comparison of trajectory prediction (L2, m) and collision rate (%) on the NVIDIA PhysicalAI-AV dataset. C and R denote camera and radar, respectively. Bold indicates the best performance.

Method	Sensors	L2 (m) ↓				Collision Rate (%) ↓			
		1s	2s	3s	Avg.	1s	2s	3s	Avg.
Prior VLM/VLA Models (Trained on nuScenes)									
AutoVLA	3×C	4.166	7.090	10.142	7.133	0.894	1.845	3.030	1.923
OpenEMMA	1×C	1.849	3.113	4.415	3.126	10.566	1.901	3.654	2.041
AutoDrive-R^2	1×C	0.817	1.465	2.276	1.520	0.233	0.583	1.049	0.622
Prior VLM/VLA Models (Trained on NVIDIA PhysicalAI-AV)									
Alpamayo 1	4×C	0.088	0.261	0.527	0.292	0.000	0.000	0.045	0.015
Alpamayo 1.5	4×C	0.091	0.303	0.653	0.349	0.000	0.010	0.130	0.046
DriveWAM	1×C	0.119	0.305	0.602	0.342	0.000	0.058	0.207	0.088
SimWAM	1×C	0.155	0.295	0.556	0.335	0.000	0.000	0.104	0.035
RaPhy-AD (Trained on NVIDIA PhysicalAI-AV, Ours)									
SFT (w/o Rationale.)	1×C+R	0.093	0.263	0.544	0.300	0.000	0.039	0.181	0.073
SFT (w/ Rationale.)	1×C+R	0.103	0.238	0.466	0.269	0.000	0.019	0.130	0.050
SFT + GRPO	1×C+R	**0.072**	**0.126**	**0.236**	**0.144**	**0.000**	**0.000**	**0.042**	**0.014**

- RaPhy-AD (SFT + GRPO)는 모든 비교 모델 중 **가장 낮은 trajectory error를 달성**
- RaPhy-AD는 평균 L2 error 0.144 m로, Alpamayo 1의 0.292 m 대비 **약 50.7% 낮은 오차를 기록**
- 3초 시점의 L2 error를 0.527 m에서 0.236 m로 감소시키면서도 **낮은 collision rate를 유지**
- 이는 **Radar 기반 물리 정보 grounding이** vision-only VLM/VLA 대비 더 정확한 trajectory prediction에 효과적임을 증명함

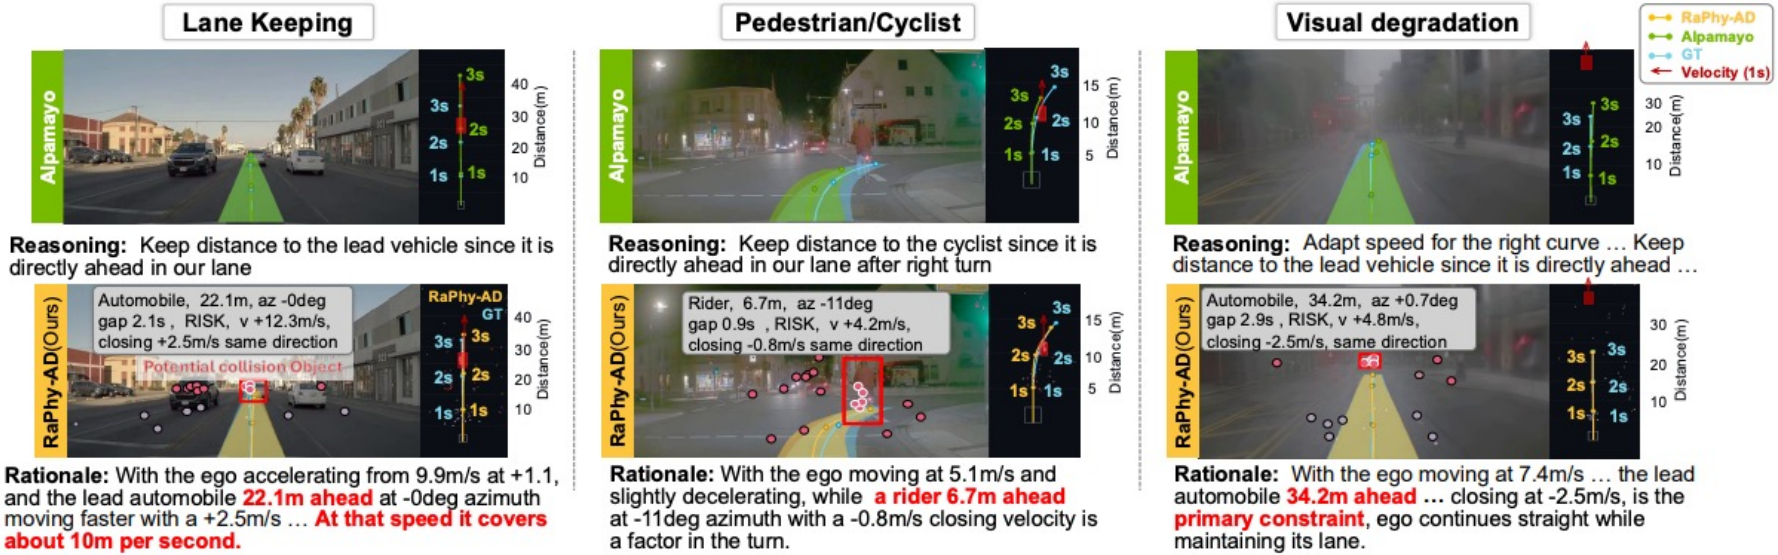
Zero-shot Evaluation

Table 3: Zero-shot evaluation on nuScenes.

Method	L2 (m) ↓				Collision (%) ↓			
	1s	2s	3s	Avg.	1s	2s	3s	Avg.
Prior Methods								
ST-P3	1.330	2.110	2.900	2.110	0.230	0.620	1.270	0.710
UniAD	0.450	0.700	1.040	0.730	0.620	0.580	0.630	0.610
OccNet	1.290	2.130	2.990	2.140	0.210	0.590	1.370	0.720
VAD	0.410	0.700	1.050	0.720	0.070	0.170	0.410	0.220
SparseDrive	0.290	0.580	0.960	0.610	0.010	0.050	0.180	0.080
DiffusionDrive	0.270	0.540	0.900	0.570	0.030	0.050	0.160	0.080
SimWAM	0.290	0.820	1.770	0.960	**0.000**	**0.030**	**0.110**	**0.050**
RaPhy-AD (Ours)								
SFT (w/o Rat.)	0.188	0.458	0.841	0.496	0.01	0.064	0.209	0.071
SFT (w/ Rat.)	0.160	0.401	0.771	0.443	0.020	0.044	0.144	0.069
SFT + GRPO	**0.157**	**0.385**	**0.722**	**0.422**	0.010	0.039	0.166	0.072

- RaPhy-AD는 nuScenes에 **추가 학습 없이** 적용한 zero-shot 설정에서도 경쟁력 있는 일반화 성능을 보임
- 이는 표의 기존 방법 중 가장 낮은 평균 L2 error를 보인 DiffusionDrive의 0.570 m보다 약 **26% 낮은 오차**
- Rationale supervision과 GRPO를 순차적으로 적용할수록 0.496 → 0.443 → 0.422 m로 오차가 감소함
- Structured physical reasoning과 RLVR이 unseen domain에서도 효과적임을 보임

Qualitative Results

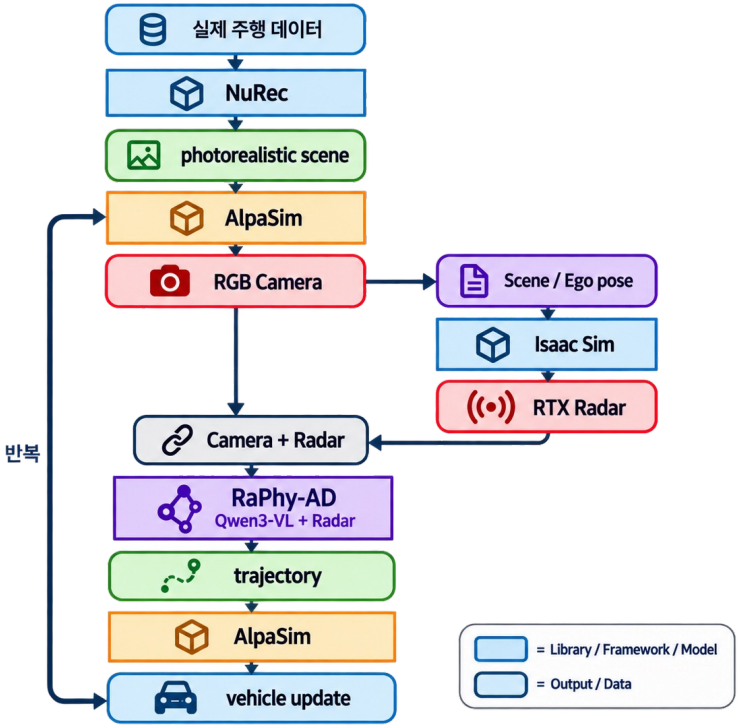


- **Lane Keeping:** Alpamayo는 단순히 앞차와의 거리 유지를 설명하지만, RaPhy-AD는 22.1 m 거리와 +2.5 m/s 상대운동을 근거로 감속 필요성을 설명
- **Pedestrian/Cyclist:** Alpamayo는 cyclist와의 거리 유지 수준에 그치지만, RaPhy-AD는 6.7 m 거리, −11° 방위각, −0.8m/s closing velocity를 활용해 회전 시 상호작용을 설명
- **Visual Degradation:** Alpamayo는 시각적 정보에 의존한 일반적 reasoning을 생성하는 반면, RaPhy-AD는 34.2 m 거리와 −2.5 m/s closing velocity를 근거로 저가시성 환경에서도 주행 판단을 설명

Autonomous Simulation 관련 경험

1. NVIDIA Omniverse NuRec
2. NVIDIA Drive Simulation

NVIDIA Omnivers NuRec



NVIDIA 기반 Closed-loop Simulation Pipeline

1. Real-world Scene Reconstruction
   - 실제 주행 데이터를 NuRec으로 simulation 재구성
   - Photorealistic driving scene 생성

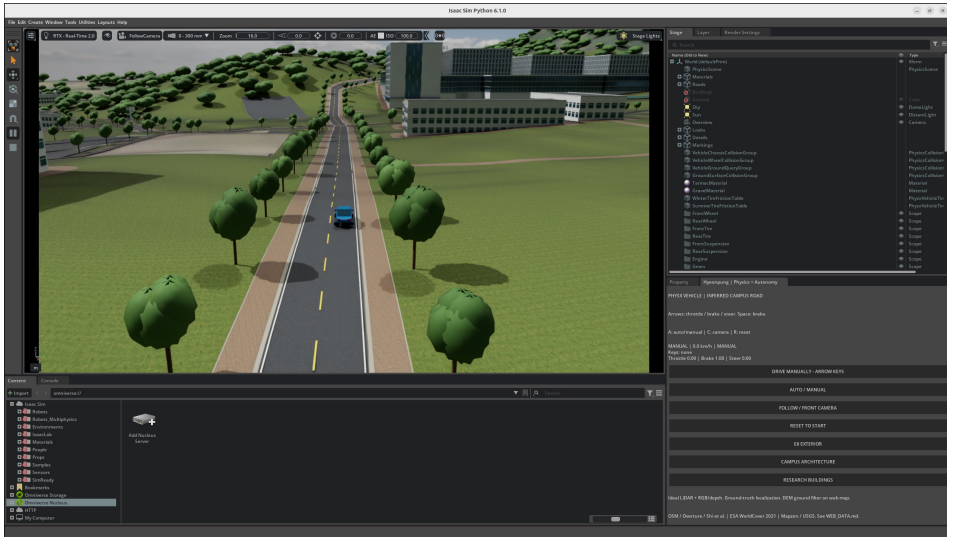
2. Multi-sensor Simulation
   - AlpaSim에서 RGB+Radar observation 생성
   - Ego pose를 Isaac Sim과 연동하여 RTX Radar 데이터 생성

3. RaPhy-AD Inference
   - Camera + Radar를 Autonomous Model에 입력
   - 주행 trajectory 예측

4. Closed-loop Evaluation
   - 예측 trajectory를 AlpaSim에 반영
   - Vehicle state를 업데이트하며 반복 평가

NVIDIA Drive Simulation





- 현풍 DGIST 캠퍼스의 도로·건물·주변 지형을 반영한 3D 주행 환경 구축
- 구축한 캠퍼스 맵에 차량을 배치하고, 도로 구간에서 주행 시뮬레이션 수행

감사합니다

CONTACT
Phone : 010-8977-8501
E-mail : jwshin@dgist.ac.kr
CV : https://jeongwan-shin.github.io/
Git : https://github.com/Jeongwan-Shin